

ĐẠI HỌC QUỐC GIA TP.HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



BÁO CÁO ĐỒ ÁN
NHẬN DẠNG

ĐỀ TÀI

FreqNet: Nhận diện Deepfake sử dụng không gian tần số

Giảng viên hướng dẫn: TS. Dương Việt Hằng

Sinh viên thực hiện:

Nguyễn Việt Nguyên - 23521054

Nguyễn Việt Hùng - 23520571

TP. Hồ Chí Minh, Tháng 5 năm 2026

Mục lục

1	Phân công	3
2	Giới thiệu	4
2.1	Lý do chọn bài toán	4
2.1.1	Thực trạng và mối nguy hại từ Deepfake:	4
2.1.2	Cơ chế cốt lõi của công nghệ sinh ảnh giả mạo (GAN)	4
2.1.3	Tính cấp thiết của đề tài	5
2.2	Phát biểu bài toán	5
3	Nghiên cứu liên quan	6
3.1	Phương pháp dựa trên Miền không gian ảnh (Spatial Domain)	6
3.2	Phương pháp dựa trên Miền tần số (Frequency Domain)	6
3.3	Phương pháp dựa trên Miền Gradient (Gradient Domain)	7
3.4	Phương pháp dựa trên Miền đặc trưng trích xuất (Foundation Models / Semantic Features)	7
4	Phương pháp của bài báo	8
4.1	Giới thiệu chung về FreqNet	8
4.2	Nhược điểm của các phương pháp tần số trước FreqNet	8
4.3	So sánh phương pháp tần số cũ và phương pháp FreqNet	9
4.3.1	Phương pháp tiếp cận truyền thống	9
4.3.2	Phương pháp FreqNet	9
4.4	Ưu điểm vượt trội của FreqNet	10
4.5	Cơ sở toán học: Khái niệm DFT và thuật toán FFT	10
4.6	Các khối thành phần trong kiến trúc FreqNet	11
4.6.1	Khối HFRI (High-Frequency Representation of Images)	11
4.6.2	Khối HFRF (High-Frequency Representation of Features)	12
4.6.3	Khối FCL (Frequency Convolutional Layer)	12
4.7	Điểm nhấn kỹ thuật của FreqNet nguyên bản	13
5	Phương pháp đề xuất	14
5.1	Động lực cải tiến	14
5.2	Mô hình toán học của cơ chế cải tiến	14
5.2.1	Công thức phân vùng mặt nạ	14
5.2.2	Phép toán lọc phổ	15
5.3	Tái cấu trúc các khối thành phần	15
5.3.1	Khối MS-HFRI (Mask-Softened HFRI)	15
5.3.2	Khối MS-HFRF (Mask-Softened HFRF)	16
5.4	Hiệu quả mong đợi	16

6	Thực nghiệm	17
6.1	Chiến lược huấn luyện	17
6.2	Bộ dữ liệu	17
6.3	Độ đo đánh giá	17
6.4	Các tham số cài đặt	18
6.5	Kết quả	18
7	Demo ứng dụng	20
7.1	Công nghệ sử dụng	20
7.2	Quy trình hoạt động của demo	20
7.3	Đường dẫn demo:	20
	Tài liệu tham khảo	22

Chương 1: Phân công

Họ và tên	MSSV	Công việc	% đóng góp tổng 100%
Nguyễn Việt Nguyên	23521054	Tìm hiểu bài báo FreqNet, đề xuất phương pháp adaptive, tìm dữ liệu, xây dựng lại và huấn luyện baseline	50%
Nguyễn Việt Hùng	23520571	Tìm hiểu các nghiên cứu có liên quan, xây dựng và huấn luyện mô hình adaptive, đánh giá kết quả và triển khai demo	50%

Bảng 1.1: Bảng phân chia công việc nhóm

Chương 2: Giới thiệu

2.1 Lý do chọn bài toán

Trong những năm gần đây, sự phát triển vượt bậc của trí tuệ nhân tạo (AI) và học sâu (Deep Learning) đã mang lại nhiều đột phá trong xử lý hình ảnh và video. Tuy nhiên, sự phát triển này cũng kéo theo những hệ lụy khó lường về mặt an ninh và bảo mật thông tin, nổi bật nhất là sự xuất hiện của công nghệ Deepfake.

2.1.1 Thực trạng và mối nguy hại từ Deepfake:

Deepfake – thuật ngữ kết hợp giữa "Deep learning" (Học sâu) và "Fake" (Giả mạo) – là công nghệ sử dụng các mô hình học sâu để thu thập, phân tích và tái tạo lại khuôn mặt, giọng nói cũng như cử chỉ của con người từ các nguồn dữ liệu có sẵn. Khả năng tổng hợp dữ liệu của Deepfake tinh vi đến mức tạo ra những video, hình ảnh giả mạo hoàn toàn tự nhiên, khiến mắt thường của con người gần như không thể phân biệt được.

Sự nguy hiểm của Deepfake không còn dừng lại ở mức độ cảnh báo lý thuyết mà đã trở thành mối đe dọa trực tiếp đến đời sống xã hội:

- **Lừa đảo tài chính:** kẻ xấu lợi dụng cuộc gọi video call Deepfake giả mạo người thân, cấp trên để thực hiện các hành vi vay tiền, chuyển khoản nhằm chiếm đoạt tài sản.
- **Xâm phạm danh dự và bôi nhọ:** dùng deepfake để ghép mặt các cá nhân, người nổi tiếng vào các nội dung đồi trụy hoặc nhạy cảm mà không có sự đồng ý.
- **Thao túng thông tin và chính trị:** việc tạo ra các phát ngôn giả mạo của các nhà lãnh đạo có thể dẫn đến định hướng sai lệch dư luận, gây bất ổn an ninh và khủng hoảng truyền thông quốc tế.

2.1.2 Cơ chế cốt lõi của công nghệ sinh ảnh giả mạo (GAN)

Sự tiến hóa của Deepfake gắn liền với sự phát triển của Mạng đối kháng tạo sinh (Generative Adversarial Networks - GAN), một kiến trúc học sâu được giới thiệu bởi Ian Goodfellow và các cộng sự vào năm 2014 tại hội nghị NIPS. GAN chính là công nghệ đứng sau việc tạo ra các dữ liệu giả lập có độ chân thực cao.

Cơ chế hoạt động của GAN dựa trên nguyên lý của một trò chơi đối kháng giữa hai mạng nơ-ron:

- **Bộ tạo sinh (Generator - G):** Đóng vai trò như một kẻ làm giả, cố gắng học phân phối dữ liệu thật để tạo ra các mẫu dữ liệu giả (x_{fake}) sao cho giống thật nhất có thể.
- **Bộ phân biệt (Discriminator - D):** Đóng vai trò như một cảnh sát, nhận đầu vào là cả dữ liệu thật (x_{real}) lẫn dữ liệu giả (x_{fake}) nhằm mục đích phân loại chính xác nguồn gốc của chúng.

Trong quá trình huấn luyện, hai mạng này liên tục tối ưu hóa lẫn nhau thông qua một hàm loss đối kháng. Quá trình này lặp đi lặp lại cho đến khi hệ thống đạt đến trạng thái cân bằng Nash (Nash equilibrium), nơi mà Generator tạo ra những hình ảnh hoàn hảo tới mức Discriminator không thể phân biệt được nữa (xác suất đoán đúng chỉ còn 50%).

2.1.3 Tính cấp thiết của đề tài

Chính vì các mô hình GAN ngày càng tối ưu, các dấu vết giả mạo (artifacts) ở miền không gian (pixel) ngày càng bị xóa nhòa, khiến các phương pháp nhận diện truyền thống dần mất đi hiệu quả. Nếu không có những công cụ phát hiện tự động và mạnh mẽ, niềm tin của con người sẽ ngày càng mất niềm tin vào thông tin số.

Do đó, việc nghiên cứu và phát triển các phương pháp tiên tiến nhằm Phát hiện Deepfake – cụ thể là hướng tiếp cận khai thác các đặc trưng trong miền tần số nhằm tìm kiếm những bất thường mà GAN để lại – không chỉ mang tính thời sự cao mà còn là nhiệm vụ cấp thiết để bảo vệ an ninh thông tin, giảm thiểu rủi ro lừa đảo công nghệ cao trong kỷ nguyên số.

2.2 Phát biểu bài toán

1. Input: Đầu vào cơ bản của hệ thống là một bức ảnh, được biểu diễn dưới dạng $x \in \mathbb{R}^{W \times H \times 3}$. Bức ảnh này có thể là ảnh gốc (thật) hoặc ảnh do AI tạo ra (giả)
2. Output: Đầu ra của mô hình là kết quả dự đoán của một bộ phân loại nhị phân với 2 nhãn
 - 0: Bức ảnh là ảnh thật.
 - 1: Bức ảnh là ảnh giả mạo (deepfake).

Chương 3: Nghiên cứu liên quan

Hiện nay, các phương pháp phát hiện và phân loại ảnh/video giả mạo (Deepfake) rất đa dạng. Dựa trên bản chất của đặc trưng mà mô hình khai thác, các phương pháp tiếp cận cốt lõi được chia thành 4 nhóm chính: Miền không gian ảnh, Miền tần số, Miền Gradient, và Miền đặc trưng trích xuất.

3.1 Phương pháp dựa trên Miền không gian ảnh (Spatial Domain)

Công bố: Phương pháp được công bố trong bài báo **FaceForensics++: Learning to Detect Manipulated Facial Images** được đăng trên hội nghị **ICCV 2019** [1]

Khái niệm và Cơ chế: Miền không gian của ảnh thực chất là ma trận biểu diễn các giá trị điểm ảnh (pixels). Phương pháp này sử dụng các kiến trúc mạng nơ-ron tích chập (chủ yếu là CNN) để phân tích trực tiếp trên ma trận điểm ảnh này. Mục tiêu của mạng là tìm kiếm các dấu vết giả mạo trực quan để lại trong quá trình ghép hoặc tái tạo cấu trúc khuôn mặt.

Đặc trưng khai thác: Mô hình tập trung nhận diện các lỗi toán học hoặc vật lý hiển thị trên bề mặt ảnh như: lỗi trộn viền (blending artifacts) tại ranh giới vùng mặt bị thay thế, sự sai lệch về hướng ánh sáng hoặc bóng đổ giữa vùng mặt và nền, hoặc sự bất thường về độ sắc nét/độ nhòe cục bộ.

Hạn chế: Các phương pháp trên miền không gian có khả năng tổng quát kém (low generalizability). Mô hình rất dễ bị "học vẹt" (overfitting) vào các dấu vết giả mạo (artifacts) cụ thể của từng bộ dữ liệu huấn luyện hoặc một thuật toán GAN nhất định. Khi đối mặt với các dạng Deepfake mới chưa từng xuất hiện trong quá trình train, hiệu năng phân loại của hệ thống thường bị giảm mạnh.

3.2 Phương pháp dựa trên Miền tần số (Frequency Domain)

Công bố: Phương pháp được công bố trong bài báo **Leveraging Frequency Analysis for Deep Fake Image Recognition** được đăng trên hội nghị **ICML 2020** [2]

Khái niệm và Cơ chế: Thay vì phân tích giá trị pixel, phương pháp này dịch chuyển dữ liệu ảnh từ miền không gian sang miền tần số (thường thông qua biến đổi Fourier) để kiểm tra phân phối năng lượng của các dải tần.

Đặc trưng khai thác:

- **Hình ảnh thực:** Thường có phổ tần số mượt mà, năng lượng tập trung chủ yếu ở dải tần số thấp (thông tin cấu trúc lớn) và giảm dần ở dải tần số cao.
- **Hình ảnh Deepfake:** Xuất hiện các dấu vết bất thường (artifacts) rất rõ ràng dưới dạng các đường lưới (grid patterns) hoặc các điểm sáng lạ trong phổ tần số. Đây là

hệ quả tất yếu để lại do quá trình tăng mẫu (up-sampling) hoặc các phép toán tích chập chuyển vị (transposed convolution) của mạng sinh tạo ra.

Hạn chế: Hiệu năng bị phụ thuộc nặng nề vào đặc trưng tần số riêng biệt của từng kiến trúc mạng sinh. Do mỗi biến thể mạng GAN có cơ chế up-sampling và cấu trúc tầng khác nhau, các lưới nhiễu tần số tạo ra cũng hoàn toàn khác nhau. Điều này khiến mô hình miền tần số truyền thống trở nên kém ổn định khi công nghệ sinh ảnh thay đổi hoặc cập nhật.

3.3 Phương pháp dựa trên Miền Gradient (Gradient Domain)

Công bố: Phương pháp được công bố trong bài báo **Learning on Gradients: Generalized Artifacts Representation for GAN-Generated Images Detection** được đăng trên hội nghị **CVPR 2023** [3]

Khái niệm và Cơ chế: Miền gradient không tập trung vào giá trị màu sắc tuyệt đối của điểm ảnh mà tập trung vào sự thay đổi (đạo hàm bậc nhất/bậc hai) giữa các giá trị điểm ảnh liền kề. Ảnh gốc sẽ được chuyển đổi sang miền ma trận gradient trước khi đưa vào mô hình phân loại.

Đặc trưng khai thác: Phương pháp này tìm kiếm các điểm bất thường về mặt cấu trúc và kết cấu bề mặt (texture artifacts). Bản chất của các thuật toán tạo ảnh giả là cố gắng làm mịn bề mặt để đánh lừa mắt người, tuy nhiên việc này vô tình làm thay đổi đột ngột phân phối của các vector gradient (hướng và biên độ thay đổi dòng pixel), khiến các vùng biên cạnh bị mất đi tính tự nhiên.

Hạn chế: Độ bền vững rất kém trước các tác động nhiễu môi trường (low robustness). Do đặc tính toán học của phép tính đạo hàm, miền gradient cực kỳ nhạy cảm với các thao tác nén ảnh (compression), làm mờ (blur), hoặc nhiễu hạt (noise). Khi ứng dụng vào dữ liệu thực tế trên Internet (vốn thường bị nén mạnh khi tải lên các nền tảng mạng xã hội), độ chính xác của phương pháp này bị suy giảm nghiêm trọng.

3.4 Phương pháp dựa trên Miền đặc trưng trích xuất (Foundation Models / Semantic Features)

Công bố: Phương pháp được công bố trong bài báo **Towards Universal Fake Image Detectors that Generalize Across Generative Models** được đăng trên hội nghị **CVPR 2023** [4]

Khái niệm và Cơ chế: Phương pháp này dựa trên giả định rằng các mô hình nền tảng lớn (Foundation models) đã được huấn luyện trên lượng dữ liệu khổng lồ có khả năng nhận biết và hiểu sâu sắc về thế giới quan thực tế. Do đó, hệ thống sẽ sử dụng các mô hình pre-trained này để trích xuất các đặc trưng ngữ nghĩa mức cao (high-level semantic features) từ hình ảnh đầu vào.

Đặc trưng khai thác: Mô hình kiểm tra tính hợp lý về mặt ngữ nghĩa và logic của bức ảnh. Ví dụ như sự bất tương xứng về hình học (hai mắt không đối xứng, hình dáng tai bất thường), hoặc các chi tiết phi lý trong bối cảnh (phụ kiện, khuyên tai hai bên không giống nhau, răng bị biến dạng).

Hạn chế: Do mô hình chủ yếu tập trung vào việc hiểu nội dung tổng thể và ngữ nghĩa toàn cục của bức ảnh, nó thường bỏ qua các sai khác nhỏ hoặc các dấu vết giả mạo siêu mịn ở cấp độ pixel (pixel-level artifacts). Bên cạnh đó, việc sử dụng các mô hình nền tảng lớn đòi hỏi chi phí tính toán (computational cost) và tài nguyên phần cứng rất cao, gây khó khăn cho việc triển khai thực tế.

Chương 4: Phương pháp của bài báo

Đầu tiên nhóm sẽ giới thiệu mô hình mà nhóm đã chọn để giải quyết bài toán này và sau đó là phương pháp cải thiện mà nhóm đề xuất

4.1 Giới thiệu chung về FreqNet

FreqNet (Frequency Space Learning Network) [5] là một kiến trúc mạng học sâu tiên tiến được thiết kế chuyên biệt cho bài toán nhận diện Deepfake tổng quát (Generalizable Deepfake Detection).

Khác biệt cốt lõi của FreqNet so với các kiến trúc phân loại thông thường nằm ở chiến lược tiếp cận dữ liệu. Mô hình không cố gắng tìm kiếm các sai lệch hình thái ở miền không gian ảnh (pixel) – nơi cấu trúc dữ liệu thay đổi liên tục và dễ bị nhiễu. Thay vào đó, FreqNet tích hợp các khối học tập (plugin modules) gọn nhẹ bao gồm HFRI (High-Frequency Representation of Image), HFRF (High-Frequency Representation of Feature) và FCL (Frequency Convolutional Layer). Hệ thống này bắt buộc toàn bộ bộ phân loại CNN (Backbone) phải vận hành, trích xuất đặc trưng và tối ưu hóa các trọng số toán học trực tiếp bên trong miền không gian tần số (Frequency Space).

Mục tiêu tối thượng của kiến trúc này là xây dựng một bộ lọc thông minh có khả năng nhận diện các ảnh giả mạo từ những mô hình sinh tạo hoàn toàn mới, ngay cả khi kịch bản huấn luyện bị giới hạn về mặt dữ liệu.

4.2 Nhược điểm của các phương pháp tần số trước FreqNet


Trước khi FreqNet ra đời, phân tích tần số đã được chứng minh là một công cụ mạnh mẽ để phát hiện ảnh giả mạo nhờ vào việc phát hiện các dấu vết để lại do quá trình tăng mẫu (up-sampling) hoặc tích chập chuyển vị của các mô hình GAN. Tuy nhiên, các phương pháp truyền thống này bộc lộ điểm yếu chí mạng khi đối mặt với các kịch bản thực tế do hai nguyên nhân cốt lõi:

- **Sự đa dạng và tiến hóa của công nghệ sinh ảnh:** Các artifact (dấu vết giả mạo) trên miền tần số không phải là một hằng số cố định. Nghiên cứu thực nghiệm chứng minh rằng, mỗi kiến trúc mạng sinh (ví dụ: ProGAN, StyleGAN, BigGAN, CycleGAN...) sở hữu một cấu trúc tầng ẩn và cơ chế up-sampling riêng biệt. Do đó, các lưới nhiễu tần số tạo ra trên phổ Fourier của chúng hoàn toàn khác nhau. Thậm chí, cùng một mạng GAN nhưng khi huấn luyện trên hai tập dữ liệu khác nhau (như StyleGAN trên bộ dữ liệu ảnh phòng ngủ LSUN so với BigGAN trên ImageNet) cũng sinh ra các đặc trưng tần số khác nhau.
- **Hạn chế của việc trích xuất tần số cố định:** Do các phương pháp cũ sử dụng các bộ lọc hoặc thuật toán trích xuất đặc trưng tần số tĩnh (tần số cố định), mô hình của họ vô tình bị overfitting vào hình thái nhiễu cụ thể của tập dữ liệu huấn

luyện. Khi kiểm thử trên một mô hình sinh ảnh mới chưa từng xuất hiện trong quá trình học, các đường lưới tần số thay đổi cấu trúc, khiến hệ thống phân loại truyền thống hoàn toàn mất đi khả năng nhận diện.

4.3 So sánh phương pháp tần số cũ và phương pháp FreqNet


4.3.1 Phương pháp tiếp cận truyền thống



Hình 4.1: Minh hoạ phương pháp truyền thống.

- **Vai trò của miền tần số:** Sử dụng miền tần số như một dạng đầu vào phụ trợ (tính) hoặc một kênh thông tin bổ sung độc lập với mạng CNN chính.
- **Quy trình xử lý dữ liệu:** Trích xuất đặc trưng tần số từ ảnh gốc → Đưa đặc trưng tần số vào các lớp phân loại tích chập hoạt động trên miền không gian hình ảnh.
- **Bản chất đặc trưng học được:** Học các dấu vết cục bộ (frequency-level artifacts) riêng biệt của từng tập dữ liệu cụ thể.
- **Hệ quả kịch bản kiểm thử:** Dễ xảy ra hiện tượng quá khớp. Hiệu năng suy giảm khi gặp các cấu trúc Deepfake chưa từng thấy trước đó.

4.3.2 Phương pháp FreqNet



Hình 4.2: Minh hoạ phương pháp freqnet.

- **Vai trò của miền tần số:** Biến miền tần số thành không gian tính toán chủ đạo. Mạng CNN trực tiếp xử lý dữ liệu bên trong miền phổ.
- **Quy trình xử lý dữ liệu:** Biến đổi ảnh sang tần số → Áp dụng mặt nạ lọc thông cao → Thực hiện tích chập trực tiếp trên phổ pha và phổ biên độ → Biến đổi ngược về miền không gian.
- **Bản chất đặc trưng học được:** Học các đặc trưng độc lập nguồn sinh dựa trên bản chất toán học của các phép toán sinh ảnh.
- **Hệ quả kịch bản kiểm thử:** Tối ưu hóa năng lực tổng quát hóa. Mô hình duy trì độ chính xác cao trên các miền dữ liệu lạ.

4.4 Ưu điểm vượt trội của FreqNet

Thông qua việc dịch chuyển bài toán học máy vào không gian phổ tần số, FreqNet thiết lập những cột mốc ấn tượng về mặt hiệu năng và kiến trúc giải thuật:

- **Khả năng tổng quát hóa vượt trội:** FreqNet chứng minh sự hiệu quả áp đảo khi được thử nghiệm diện rộng trên kịch bản thế giới thực bao gồm 17 kiến trúc mạng GAN khác nhau. Mô hình đạt mức độ chính xác trung bình (Accuracy) lên tới 92.8%, tạo ra cách biệt hiệu năng tăng +9.8% so với các mô hình SOTA mạnh nhất tại thời điểm công bố (ví dụ: mô hình của Ojha - 2023 chỉ đạt 83%).
- **Kiến trúc siêu nhẹ và tối ưu tài nguyên:** Trong khi các mô hình nhận diện thể hệ mới phải đánh đổi độ chính xác bằng cách gia tăng tham số mạng lên các mức khổng lồ (Mô hình Ojha 2023 yêu cầu tới 304 triệu tham số), FreqNet tối ưu cấu trúc gọn nhẹ với chỉ vỏn vẹn 1.9 triệu tham số. Sự sụt giảm số lượng tham số hàng trăm lần này giúp giảm tải chi phí tính toán cực lớn, mở ra cơ hội triển khai thực tế trên các thiết bị phần cứng giới hạn hoặc hệ thống xử lý thời gian thực.
- **Hiệu quả cao với dữ liệu huấn luyện hạn chế:** Nhờ cơ chế bắt buộc mạng học tập các quy luật toán học cốt lõi của phổ biến đổi Fourier (Amplitude and Phase) thay vì học hình thái pixel, FreqNet không phụ thuộc vào các kỹ thuật cào dữ liệu quy mô lớn. Mô hình đạt độ hội tụ và độ chính xác rất cao ngay cả khi các tập dữ liệu dùng để huấn luyện cực kỳ nhỏ và hạn chế.

4.5 Cơ sở toán học: Khái niệm DFT và thuật toán FFT

Để chuyển đổi dữ liệu từ miền không gian (Spatial Domain) sang miền không gian tần số (Frequency Space), mô hình sử dụng công cụ toán học là Biến đổi Fourier rời rạc (Discrete Fourier Transform - DFT).

Cho một tín hiệu ảnh số rời rạc $x[n]$, phép biến đổi DFT sang thành phần tần số thứ k ($X[k]$) trong không gian N mẫu được định nghĩa qua công thức:

$$X[k] = \sum_{n=0}^{N-1} x[n] \cdot e^{-j \frac{2\pi}{N} kn}$$


Trong đó, $e^{-j \frac{2\pi}{N} kn}$ là sóng cơ sở phức và j là số ảo ($j^2 = -1$). Do độ phức tạp tính toán gốc của DFT lên tới $\mathcal{O}(N^2)$ – một chi phí quá lớn cho các mạng học sâu, FreqNet tích hợp thuật toán Biến đổi Fourier nhanh (Fast Fourier Transform - FFT).

FFT tối ưu hóa quá trình tính toán dựa trên hai bước cốt lõi:

- **Chia để trị (Divide and Conquer):** Tách biệt tín hiệu ban đầu thành các thành phần chỉ số chẵn và chỉ số lẻ.
- **Kết hợp (Combination):** Sử dụng các hệ số xoay (twiddle factors) để tổng hợp tuần tự các kết quả thành phần lại với nhau.

Nhờ cơ chế này, FFT giảm thiểu tối đa khối lượng tính toán, hạ độ phức tạp xuống chỉ còn $\mathcal{O}(N \log N)$, giúp việc xử lý miền tần số theo thời gian thực trong mạng CNN trở nên khả thi.


4.6 Các khối thành phần trong kiến trúc FreqNet



Hình 4.3: Kiến trúc tổng quan của FreqNet.

Kiến trúc tổng quan của FreqNet được cấu thành từ ba khối xử lý đặc trưng chuyên biệt: HFRI, HFRF, và FCL.

4.6.1 Khối HFRI (High-Frequency Representation of Images)



Hình 4.4: Minh hoạ khối HFRI.

- **Cơ chế vận hành:** Với mỗi ảnh đầu vào $x \in \mathbb{R}^{W \times H \times 3}$, khối HFRI thực hiện chuyển đổi ảnh sang miền tần số thông qua toán tử Biến đổi Fourier nhanh (FFT). Hệ thống định vị thành phần tần số không (zero-frequency) về trung tâm phổ. Sau đó, một mặt nạ lọc thông cao cứng (Hard High-pass Filter, ký hiệu $\mathcal{B}_h$) được áp dụng để triệt tiêu các dải tần thấp (vùng trung tâm) và cô lập phân vùng cao tần (f_h):

$$f_h = \mathcal{B}_h(\mathcal{F}(x))$$

Hàm lọc thông cao $\mathcal{B}_h(\cdot)$ đối với tọa độ tần số (i, j) lấy tâm ảnh làm gốc tọa độ được định nghĩa toán học như sau:


$$\mathcal{B}_h(f_{i,j}) = \begin{cases} 0, & \text{nếu } |i| < \frac{W}{4} \text{ và } |j| < \frac{H}{4} \\ f_{i,j}, & \text{trường hợp khác} \end{cases}$$

Sau khi lọc, dữ liệu được chuyển ngược về miền không gian ảnh bằng thuật toán Fourier ngược (iFFT):

$$x_h = \mathcal{IF}(f_h)$$

- **Ý nghĩa:** Ma trận ảnh cao tần x_h sau đó đóng vai trò là đầu vào trực tiếp cho mạng phân loại. Bước này ép mô hình phải cô lập hoàn toàn các nhiễu cấu trúc bề mặt, tập trung nhận diện các lưới nhiễu răng cưa (grid artifacts) – hệ quả không thể tránh khỏi từ các phép up-sampling trong pipeline của các mạng GAN.

4.6.2 Khối HFRF (High-Frequency Representation of Features)



Hình 4.5: Minh hoạ khối HFRF.

- **Cơ chế vận hành:** Để ngăn chặn hiện tượng các tầng ẩn bên trong mạng CNN tự động tái cấu trúc thông tin tần số thấp và làm mờ các artifact nhạy cảm, FreqNet tích hợp khối HFRF trực tiếp vào các bản đồ đặc trưng lớp ẩn.

Xét đầu ra của lớp tích chập thứ k là ma trận đặc trưng $M^k \in \mathbb{R}^{H \times W \times C}$. Khối HFRF thực hiện phép toán tách lọc cao tần song song và độc lập trên hai chiều:

- **Chiều không gian (Spatial Dimensions - W, H):** Khai thác các cấu trúc pixel cục bộ bất thường.
- **Chiều kênh tín hiệu (Channel Dimension - C):** Khai thác mối tương quan phân phối giữa các bộ lọc đặc trưng.


Công thức toán tử cho hai nhánh được biểu diễn dưới dạng:

$$M_h^k(W, H) = \mathcal{IF}_{W,H}(\mathcal{B}_h(\mathcal{F}_{W,H}(M^k)))$$

$$M_h^k(C) = \mathcal{IF}_C(\mathcal{B}_h(\mathcal{F}_C(M^k)))$$

- **Ý nghĩa:** Việc trích xuất cao tần đa chiều (M_h^k) ở các tầng sâu giúp duy trì độ nhạy cảm của mô hình đối với các dấu vết giả mạo siêu mịn ở mọi cấp độ trừu tượng, triệt tiêu xu hướng "học vẹt" hình thái nội dung tổng thể của tập huấn luyện.

4.6.3 Khối FCL (Frequency Convolutional Layer)



Hình 4.6: Minh hoạ khối FCL.

- **Cơ chế vận hành:** Khối FCL là hạt nhân cốt lõi thực hiện hành vi "học tập trong không gian tần số". Thay vì chỉ sử dụng miền tần số làm bộ lọc tĩnh, FCL thực hiện tính toán cập nhật trọng số trực tiếp trên phổ.

Bản đồ đặc trưng lớp ẩn M^k được biến đổi FFT sang miền tần số phức:

$$f = f_{am} + f_{ph}i = \mathcal{F}_{W,H}(M^k)$$

Trong đó, f_{am} là Phổ biên độ (Amplitude Spectrum) nắm giữ thông tin cường độ năng lượng tần số, và f_{ph} là Phổ pha (Phase Spectrum) nắm giữ cấu trúc hình học phức tạp của ảnh.

FreqNet triển khai các lớp tích chập độc lập (L_{conv}) tính toán song song trực tiếp trên hai thành phần phổ này để thu được phổ đã qua học tập:

$$\tilde{f}_{am} = L_{conv}(f_{am})$$

$$\tilde{f}_{ph} = L_{conv}(f_{ph})$$

Cuối cùng, ma trận đặc trưng mới $\tilde{M}^k$ được tái tạo thông qua toán tử iFFT từ tổng phổ phức đã tối ưu:

$$\tilde{M}^k = \mathcal{IF}_{W,H}(\tilde{f}_{am} + \tilde{f}_{ph}i)$$

- **Ý nghĩa:** Nhờ cơ chế này, mô hình có khả năng học được các đặc trưng độc lập với nguồn sinh. Lớp tích chập trên phổ biên độ và phổ pha cho phép mạng CNN nhận diện quy luật toán học chung của các thuật toán tạo ảnh giả mà không bị ràng buộc bởi phong cách hình ảnh cụ thể của từng dataset.

4.7 Điểm nghẽn kỹ thuật của FreqNet nguyên bản

Mặc dù FreqNet tạo ra bước đột phá về hiệu năng phân loại tổng quát trên 17 kiến trúc GAN nhờ tập trung vào cao tần, nhóm cũng nhận thấy một hạn chế nằm ở cơ chế Mặt nạ lọc cứng (Hard Masking) của bộ lọc $\mathcal{B}_h$.

Việc thiết lập giá trị bằng 0 tuyệt đối cho tất cả các thành phần có tần số $|i| < W/4$ và $|j| < H/4$ đã loại bỏ hoàn toàn dải tần số thấp. Trên khía cạnh lý thuyết xử lý ảnh thông tin, dải tần số thấp tuy không chứa lưới nhiễu GAN nhưng lại là nơi lưu trữ thông tin cấu trúc nền tảng, bối cảnh toàn cục (global layout) và phân phối năng lượng gốc của bức ảnh. Việc triệt tiêu hoàn toàn dải tần này khiến mô hình bị mất đi các thông tin ngữ nghĩa quan trọng, dẫn đến nguy cơ mất ổn định hoặc giảm độ chính xác khi đối mặt với các biến thể ảnh thực tế bị nén mạnh, làm mờ, hoặc thay đổi điều kiện ánh sáng trong môi trường tự nhiên.

Chương 5: Phương pháp đề xuất

5.1 Động lực cải tiến

Trong kiến trúc FreqNet nguyên bản, khối HFRI và HFRF sử dụng cơ chế Mặt nạ lọc cứng (Hard Masking). Bộ lọc thông cao $\mathcal{B}_h$ hoạt động theo nguyên lý nhị phân: giữ nguyên dải tần cao và triệt tiêu toàn bộ (gán bằng 0) dải tần số thấp ở trung tâm phổ Fourier.

Tuy nhiên, việc cắt bỏ hoàn toàn dải tần số thấp dẫn đến rủi ro mất mát thông tin ngữ nghĩa nghiêm trọng. Trong lý thuyết xử lý ảnh số, dải tần số thấp nắm giữ các thông tin nền tảng về cấu trúc hình học tổng thể, bối cảnh toàn cục và phân phối năng lượng chính của bức ảnh. Việc thiếu đi các thông tin này khiến mạng Backbone CNN dễ bị mất ổn định hoặc giảm độ chính xác khi đối mặt với các kịch bản ảnh thực tế bị nhiễu, làm mờ, hoặc nén mạnh.

Để giải quyết điểm nghẽn này, phương pháp cải tiến đề xuất một **Cơ chế lọc mềm thích nghi (Adaptive Soft Masking)**. Cơ chế này giữ nguyên toàn bộ dải tần số cao với hệ số mặc định là 1 nhằm bảo toàn các artifact giả mạo, đồng thời thay thế vùng cắt cứng tần số thấp bằng một ma trận trọng số có thể học được để điều tiết dòng thông tin ngữ nghĩa chảy vào mạng.

5.2 Mô hình toán học của cơ chế cải tiến

Thay vì áp dụng một bộ lọc thông cao cố định, phương pháp cải tiến định nghĩa một mặt nạ lọc thích nghi $\mathcal{M}_{adapt}$ hoạt động phân vùng trên phổ tần số $F = \mathcal{F}(X)$ sau phép biến đổi FFT.

5.2.1 Công thức phân vùng mặt nạ

Giả sử phổ tần số F có kích thước $W \times H$ với tâm phổ làm gốc tọa độ. Mặt nạ thích nghi $\mathcal{M}_{adapt}$ tại vị trí tọa độ tần số (i, j) được cấu trúc như sau:

$$\mathcal{M}_{adapt}(i, j) = \begin{cases} \sigma(W_m(i, j)), & \text{nếu } |i| < \frac{W}{4} \text{ và } |j| < \frac{H}{4} \quad (\text{Dải tần số thấp}) \\ 1, & \text{trường hợp khác} \quad (\text{Dải tần số cao}) \end{cases}$$

Trong đó:

- $\sigma(\cdot)$ là hàm kích hoạt Sigmoid giúp ép các giá trị trọng số rơi vào khoảng mềm $(0, 1)$.
- W_m là ma trận trọng số học được (learnable weights) có kích thước tương ứng với vùng tần số thấp $(\frac{W}{2} \times \frac{H}{2})$. Các tham số này được khởi tạo ngẫu nhiên và sẽ được tối ưu hóa liên tục thông qua quá trình lan truyền ngược (Backpropagation).

5.2.2 Phép toán lọc phổ

Phổ tần số sau khi đi qua bộ lọc mềm phân vùng sẽ được tính bằng phép nhân Hadamard (nhân từng phần tử):


$$\tilde{F} = \mathcal{M}_{adapt} \odot F$$

Nhờ cơ chế này, các đặc trưng tần số cao (nơi chứa dấu vết grid artifacts của GAN) được cho qua hoàn toàn với trọng số bằng 1. Trong khi đó, các thành phần tần số thấp được nhân với hệ số điều tiết thích nghi $\sigma(W_m)$, cho phép một lượng năng lượng cấu trúc vừa đủ đi vào mạng nơ-ron để làm mờ neo ngữ nghĩa.

5.3 Tái cấu trúc các khối thành phần

Sau khi tích hợp cơ chế lọc mềm phân vùng, các khối module trong FreqNet vận hành như sau:

5.3.1 Khối MS-HFRI (Mask-Softened HFRI)




Hình 5.1: Minh họa khối MS-HFRI với phần tần số thấp ở trung tâm được tô màu xanh biển thể hiện cơ chế thích nghi.

Ảnh gốc X được chuyển sang miền phổ bằng FFT, nhân với mặt nạ thích nghi phân vùng $\mathcal{M}_{adapt}$ và đưa ngược về miền không gian thông qua iFFT:

$$x_{soft_h} = \mathcal{IF}(\mathcal{M}_{adapt} \odot \mathcal{F}(X))$$

Ma trận ảnh đầu ra x_{soft_h} lúc này vừa làm nổi bật rõ nét các lưới nhiễu cao tần của AI, vừa giữ lại được các đường nét hình thái hình học mờ của khuôn mặt gốc, giúp mạng CNN dễ dàng định vị vùng đặc trưng.

5.3.2 Khối MS-HFRF (Mask-Softened HFRF)



Hình 5.2: Minh hoạ khối MS-HFRF với phần tần số thấp ở trung tâm được tô màu xanh biển thể hiện cơ chế thích nghi.

Cơ chế tương tự được áp dụng cho các bản đồ đặc trưng (feature maps) lớp ẩn sâu bên trong mạng. Việc điều tiết mềm dải tần thấp giúp duy trì mối tương quan chặt chẽ giữa kết cấu bề mặt bị chỉnh sửa cục bộ (cao tần) và cấu trúc giải phẫu học toàn cục của khuôn mặt (thấp tần).

5.4 Hiệu quả mong đợi

Việc chuyển đổi từ cơ chế mặt nạ lọc cứng sang Bộ lọc tần số thích nghi phân vùng (Adaptive Region-based Soft Masking) được kỳ vọng sẽ mang lại những cải tiến vượt trội về mặt hiệu năng và độ ổn định cho mô hình:

- **Khả năng tự động học mức độ quan trọng của dải tần số thấp:** Thay vì bị triệt tiêu hoàn toàn về mức 0 như trước, dải tần số thấp – nơi nắm giữ cấu trúc hình học tổng thể và bối cảnh nền của ảnh – giờ đây được điều tiết bởi một ma trận trọng số học được W_m . Thông qua quá trình huấn luyện, mô hình sẽ tự động phân tích và giữ lại một lượng năng lượng tần số thấp vừa đủ, đóng vai trò như một "mỏ neo ngữ nghĩa" để phù hợp với từng phân phối dữ liệu đầu vào cụ thể.
- **Tối ưu hóa linh hoạt dòng thông tin thông qua Lan truyền ngược:** Nhờ việc sử dụng hàm kích hoạt Sigmoid thay cho hàm cắt ngưỡng nhị phân, dòng Gradient có thể lan truyền liên tục qua các tầng phổ phức. Cơ chế này cho phép mạng nơ-ron tự động tối ưu hóa linh hoạt: quyết định giữ lại nhiều hơn hay triệt tiêu bớt các đặc trưng tần số thấp dựa trên phản hồi từ hàm mất mát, giúp quá trình hội tụ của mô hình diễn ra nhanh và ổn định hơn.
- **Nâng cao tính ổn định và năng lực tổng quát hóa cốt lõi:** Việc bảo toàn 100% dải tần số cao (trọng số mặc định bằng 1) giúp mô hình không bỏ sót bất kỳ artifact răng cưa nào của GAN. Đồng thời, việc bổ sung thông tin ngữ nghĩa từ dải tần thấp giúp mô hình đạt độ bền vững rất cao trước các biến đổi phá hủy cấu trúc ảnh thực tế (như nén ảnh JPEG chất lượng thấp, làm mờ Gauss, hoặc nhiễu môi trường). Kết quả mong đợi là toàn bộ hệ thống phát hiện Deepfake đạt được khả năng tổng quát hóa mạnh mẽ hơn khi đối mặt với các miền dữ liệu hoàn toàn mới.

Chương 6: Thực nghiệm

6.1 Chiến lược huấn luyện

Để đảm bảo kết quả công bằng giữa baseline và phương pháp mà nhóm đề xuất, nhóm chọn huấn luyện từ đầu (train from scratch).

6.2 Bộ dữ liệu

Thực tế, bài báo mà nhóm tham khảo được huấn luyện và đánh giá mô hình trên dataset rất lớn như ForenSynths. Vì lý do hạn chế tài nguyên phần cứng, nhóm không có khả năng huấn luyện và đánh giá trên các bộ dataset có quy mô lớn như bài báo đã làm.

Bộ dữ liệu được sử dụng là AI-Generated-vs-Real-Dataset.

Đường dẫn của bộ dữ liệu: [Bấm vào đây](#)

Dataset gồm 152.710 ảnh được gán nhãn nhị phân, trong đó:

- Nhãn 0: ảnh được tạo bởi AI (AiArtData)
- Nhãn 1: ảnh thật (RealArt)

Nhóm không dùng toàn bộ dataset đó, chỉ trích xuất ngẫu nhiên 50.000 ảnh sau đó chia:

- train: 36.000 ảnh
- validation: 4.000 ảnh
- test:: 10.000 ảnh

6.3 Độ đo đánh giá

Để thực hiện đánh giá, nhóm sẽ sử dụng các độ đo sau:

- **Parameters (Số lượng tham số)**

Cơ sở & Nguyên lý hoạt động:

Parameters (Tham số) là tổng số lượng các trọng số (*weights*) và độ lệch (*biases*) có thể học được bên trong các lớp của mạng nơ-ron (như các lớp tích chập không gian, tích chập phổ pha/biên độ,...). Trong phương pháp tần số, số lượng tham số phản ánh quy mô cấu trúc và độ phức tạp tính toán của mô hình khi xử lý các đặc trưng trong miền tần số. Vì mô hình FreqNet mà bài báo đề xuất là một mô hình nổi bật với số lượng tham số ít hơn rất đáng kể, nên việc dùng Parameters làm một độ đo đánh giá là hợp lý để có thể so sánh giữa phương pháp baseline và phương pháp nhóm đề xuất.

- **Accuracy (Độ chính xác)**

Cơ sở & Nguyên lý hoạt động:

Accuracy là tỷ lệ giữa số lượng mẫu được mô hình dự đoán chính xác (bao gồm cả ảnh thật được phân loại là thật và ảnh deepfake được phân loại là giả) trên tổng số mẫu thử nghiệm trong tập dữ liệu (*Test Set*). Độ đo này được tính toán dựa trên ma trận nhầm lẫn (*Confusion Matrix*) theo công thức tiêu chuẩn:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Đối với phương pháp miền tần số, Accuracy đo lường khả năng phân biệt thiết yếu của mô hình khi dựa vào các dấu vết bất thường (như đường lưới hay điểm sáng lạ trong phổ tần số) do thuật toán GAN để lại, so với phổ tần số mượt mà của ảnh tự nhiên.

6.4 Các tham số cài đặt

Để thực hiện quá trình huấn luyện và đánh giá bài toán, nhóm thiết lập các tham số và cấu hình chi tiết như sau:

Bảng 6.1: Cấu hình thông số huấn luyện mô hình

Thông số	Giá trị
Số lượng Epoch	20
Bộ tối ưu (Optimizer)	Adam
Hàm mất mát (Loss Function)	BCEWithLogitsLoss

Optimizer Adam và BCEWithLogisLoss được sử dụng trong code gốc của bài báo công bố, nhóm chỉ dựa theo và sử dụng lại.

6.5 Kết quả

1. Đánh giá hiệu năng

Sau quá trình huấn luyện, nhóm đã tiến hành đánh giá hiệu năng của hệ thống. Kết quả được so sánh trực tiếp với mô hình tham chiếu (baseline) là FreqNet.

Bảng 6.2 trình bày chi tiết điểm số đạt được. Ký hiệu ↑/ ↓ biểu thị rằng giá trị độ đo càng cao/ thấp thì mô hình hoạt động càng tốt

MODEL	Parameters ↓	Accuracy ↑
FreqNet	1.85M	72,16
Ours	1.85M	74,03

Bảng 6.2: So sánh hiệu năng giữa mô hình đề xuất và FreqNet.

Ưu điểm:

- **Về số lượng tham số:** Cả hai phương pháp đều duy trì một lượng tham số tương đương nhau nằm trong khoảng 1.85M (1.85 triệu tham số). Điều này chứng minh rằng giải pháp cải tiến thích nghi (adaptive) của nhóm không làm tăng độ phức tạp cấu trúc hay làm cồng kềnh mô hình. Nó giữ nguyên được lợi thế cốt lõi của phương

pháp tần số là tính toán gọn nhẹ, tiết kiệm tài nguyên và đảm bảo tốc độ xử lý nhanh.

- **Về độ chính xác:** Phương pháp cải tiến adaptive mang lại sự tăng trưởng rõ rệt về độ chính xác, tăng từ 72.16% lên 74.03% (tăng 1.87%). Trong bài toán nhận diện Deepfake tổng quát, việc cải thiện gần 2% độ chính xác mà ít phải đánh đổi bằng việc tăng nhiều tham số là một kết quả mang ý nghĩa tốt. Nó cho thấy cơ chế thích nghi đã giúp mô hình trích xuất và tập trung vào các đặc trưng dải tần hiệu quả hơn, lọc nhiễu tốt hơn so với kiến trúc FreqNet nguyên bản.

Hạn chế:

Mặc dù đạt được những kết quả khả quan, đề xuất của nhóm vẫn tồn tại một số điểm chưa tối ưu được cụ thể qua ba hạn chế trong quá trình huấn luyện:

- **Thời gian huấn luyện chưa đủ lớn:** Trong phạm vi thực nghiệm hiện tại, mô hình đang được huấn luyện chỉ với 20 epochs — một mức thiết lập tương đối khiêm tốn đối với các bài toán học sâu. Do số lượng epoch chưa đủ lớn, mô hình có thể chưa hội tụ đến trạng thái tối ưu hoàn toàn toàn cục (*global optimum*). Các trọng số trong các lớp tích chập phổ pha và biên độ vẫn còn dư địa để tinh chỉnh nhằm nhận diện tốt hơn các bất thường ở dải tần số cao. Thực tế, mô hình FreqNet được huấn luyện lên đến 100 epochs.
- **Quy mô dữ liệu huấn luyện:** Mô hình hiện tại mới chỉ được triển khai huấn luyện và đánh giá trên một phần bộ dữ liệu có quy mô nhỏ. Sự giới hạn về mặt tài nguyên phần cứng đã ngăn cản việc mở rộng quy mô huấn luyện lên các tập dữ liệu đa dạng và lớn hơn.
- **Phạm vi ứng dụng:** Phương pháp tần số hiện tại được thiết kế và tối ưu chủ yếu để khai thác các dấu vết lưới phổ (*spectral artifacts*) đặc trưng sinh ra từ cơ chế (*up-sampling*) của các mạng tạo sinh đối kháng (GAN). Tuy nhiên, công nghệ sinh ảnh đã có những bước tiến vượt bậc với sự ra đời của các mô hình khuếch tán (Diffusion Models) vốn có cơ chế khởi tạo và thêm/khử nhiễu hoàn toàn khác biệt.

Kết luận:

Nhìn chung, việc cải thiện với cơ chế adaptive đã giúp mô hình đạt được kết quả khả quan. Bất chấp các rào cản về tài nguyên phần cứng, mô hình không những bảo toàn được kiến trúc gọn nhẹ đặc trưng của FreqNet gốc mà còn cải thiện đáng kể về độ chính xác phân loại (+1.87% Accuracy).

Chương 7: Demo ứng dụng

7.1 Công nghệ sử dụng

Sử dụng thư viện mã nguồn mở gradio để xây dựng giao diện và gọi đến file đóng gói mô hình để phân loại ảnh.

7.2 Quy trình hoạt động của demo

- **Tải hình ảnh đầu vào:** Người dùng tiến hành tải một hoặc nhiều tệp hình ảnh cần phân loại lên hệ thống.
- **Kích hoạt quá trình phân loại:** Người dùng có thể chọn so sánh với baseline là mô hình FreqNet gốc. Bấm nút Analyze để hệ thống tiến hành phân loại ảnh thật/giả.
- **Hiển thị và xuất kết quả tạo sinh:** Sau khi mô hình hoàn thành, hệ thống trực tiếp hiển thị luồng kết quả phân loại ảnh hoàn chỉnh dưới dạng lưới trực quan trên màn hình chính, hoặc xem bảng thống kê kết quả ở cuối trang.

7.3 Đường dẫn demo:

Demo được triển khai trên nền tảng Huggingface, với đường dẫn: [Deepfake Detection Demo](#)

Spaces

viethung211T / Deepfake-Detection-Demo

like

0

Agents

RunnLing

Logs

App

Files

Community

Settings

DeepFake Image Detection Demo

Using FreqNet Adaptive model to detect AI generated images

Controls

Upload images...

2025_Cristiano_Ronaldo_29.png

473.5 KB

×

c29a7d29348b1a3f502803ab9d8355cc.png

1.2 MB

×

messi_2.png


1.0 MB

×

☒ Compare with Baseline

Analyze

Analysis Results



Baseline FreqNet

Fake

FreqNet Adaptive

Real



Baseline FreqNet

Real

FreqNet Adaptive

Real



Baseline FreqNet

Real

FreqNet Adaptive

Real

Aggregate Statistics

Detailed Results

Model Name

Fake / AI Generated

Real

FreqNet Adaptive	0 (0.0%)	3 (100.0%)
Baseline FreqNet	1 (33.3%)	2 (66.7%)

Use via API

Built with Gradio

Settings

Hình 7.1: Giao diện Demo thử nghiệm.

Tài liệu tham khảo

- [1] A. Rossler, D. Cozzolino, L. Verdoliva, C. Riess, J. Thies, and M. Niessner, “Face-forensics++: Learning to detect manipulated facial images,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 1–11, 2019.
- [2] J. Frank, T. Eisenhofer, L. Schönherr, A. Fischer, D. Kolossa, and T. Holz, “Leveraging frequency analysis for deep fake image recognition,” *arXiv preprint arXiv:2003.08685*, 2020.
- [3] C. Tan, Y. Zhao, S. Wei, G. Gu, and Y. Wei, “Learning on gradients: Generalized artifacts representation for gan-generated images detection,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 12105–12114, 2023.
- [4] U. Ojha, Y. Li, and Y. J. Lee, “Towards universal fake image detectors that generalize across generative models,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 24480–24489, 2023.
- [5] C. Tan, Y. Zhao, S. Wei, G. Gu, P. Liu, and Y. Wei, “Frequency-aware deepfake detection: Improving generalizability through frequency space domain learning,” in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, pp. 5052–5060, 2024.